

Архивация данных

Что это

Архивация данных — это процесс упаковки и сжатия одного или нескольких файлов в один специальный файл (архив) для экономии места на диске и удобства их передачи



Задачи архивации

- **Экономия памяти:** Специальные алгоритмы находят повторения в коде файлов и сокращают их размер без потери информации.
- **Объединение данных:** Позволяет превратить тысячи мелких файлов и папок в один документ, что сильно ускоряет их копирование.
- **Удобство передачи:** Один сжатый файл гораздо проще отправить по электронной почте, через мессенджеры или загрузить в облако.
- **Защита информации:** Большинство архиваторов позволяют установить пароль и зашифровать содержимое от посторонних.

Сжатие без потерь

При этом методе данные сжимаются так, что при распаковке получается **абсолютно точная копия** оригинала. Каждый байт возвращается на свое место.

- Для файлов: .zip, .7z, .rar, .tar.gz
- Для аудио: .flac, .alac
- Для изображений: .png, .bmp, .tiff

Сжатие с потерями

Этот метод безвозвратно удаляет часть информации, которую человеческое ухо или глаз почти не замечают. Это позволяет уменьшить размер файла в десятки раз.

- Для изображений: .jpeg, .webp
- Для аудио: .mp3, .aac, .ogg
- Для видео: .mp4 (кодеки H.264, H.265/HEVC), .mkv

Сжатие с потерями


Характеристики	Сжатие без потерь	Сжатие с потерями
Точность копии	100% совпадение с оригиналом	Часть данных удаляется навсегда
Размер файла	Уменьшается в 1.5 – 3 раза	Уменьшается в 10 – 50+ раз
Качество	Идеальное (оригинальное)	Снижается при сильном сжатии
Повторное сжатие	Безопасно, качество не теряется	Каждый раз качество ухудшается

Сжатие с потерями

- Удаление неслышимого
- Эффект маскировки
- Приоритет яркости
- Усреднение пикселей
- Статичный фон
- Запись изменений

Сжатие с потерями

<https://habr.com/ru/articles/251417/>



Сжатие с потерями

Без сжатия с потерями современный интернет перестал бы работать из-за перегрузки каналов:

- **Стриминг (YouTube, Netflix, Twitch):** Без сжатия 4K-видео требовало бы скорость интернета в несколько гигабит в секунду.
- **Онлайн-музыка (Spotify, Яндекс Музыка):** Позволяет слушать треки мгновенно даже при плохом мобильном интернете.
- **Социальные сети:** Смартфоны делают фото весом в 5–10 МБ, но VK, Telegram и WhatsApp автоматически сжимают их до 200–500 КБ для мгновенной отправки

Сжатие без потерь

В отличие от сжатия с потерями, здесь не удаляется ни один байт информации. Процесс полностью обратим: из сжатого архива всегда можно восстановить исходный файл в первоизданном виде

Сжатие без потерь

Сжатие без потерь основано на устранении статистической избыточности. Алгоритмы ищут в файле закономерности, повторы или предсказуемые последовательности и записывают их более компактным кодом.

RLE (Кодирование длин серий)

Самый простой алгоритм. Он заменяет цепочки одинаковых символов на один символ и число его повторений.


- Оригинал: ААААААААААББББВВВВВГГ
- После сжатия: А9Б4В5Г2
- Эффективность: Отлично сжимает простые рисунки, но бесполезен для обычного текста.

Алгоритм Хаффмана

Алгоритм анализирует, какие символы встречаются часто, а какие — редко. Частым символам он присваивает очень короткие двоичные коды (например, 2 бита), а редким — длинные (например, 16 бит).

- Пример: В русском тексте буквы «О» и «А» встречаются постоянно, а «Ф» и «Ъ» — редко. Вместо того чтобы тратить на каждую букву стандартные 8 или 16 бит, алгоритм Хаффмана «ужимает» самые ходовые буквы, за счет чего уменьшается общий размер текста.

Алгоритм Хаффмана



LZ77 и LZ78

Этот алгоритм лежит в основе форматов ZIP и GZIP. Он ищет в тексте повторяющиеся слова или целые фразы и заменяет их текстовыми ссылками на уже встреченный фрагмент (словарное совпадение).

- Пример: Если в договоре 50 раз встречается фраза «Общество с ограниченной ответственностью», алгоритм запишет её полностью только один раз. В остальных 49 случаях он поставит короткую ссылку вида (вернуться назад на 400 символов, скопировать 40 символов).

Особенности и ограничения

- Ограниченный коэффициент сжатия
- Зависимость от структуры
- Парадокс «сжатия сжатого»

Где применяется

1. Документы и код
2. Профессиональная фотография и графика
3. Высококачественный звук
4. Медицинские и научные данные

Предыстория

1838 год — Код Морзе: Самый первый пример сжатия на основе частотного анализа. Изобретатель Сэмюэл Морзе заметил, что в английском языке буквы «Е» и «Т» встречаются чаще всего, и присвоил им кратчайшие сигналы (точка и тире), оставив редким буквам (например, «Q» или «Z») длинные комбинации.

Рождение теории информации

- 1948 год — Теория Клода Шеннона
- 1949 год — Алгоритм Шеннона — Фано
- 1952 год — Алгоритм Хаффмана

Словарная революция

- 1977-1978 годы — Алгоритмы LZ77 и LZ78
- 1984 год — Алгоритм LZW
- Конец 1980-х — Рождение ZIP

Мультимедийный взрыв

- 1992 год — Стандарт JPEG
- 1993 год — Формат MP3
- 1990-е — Продвинутое архиваторы

Современность, Big Data и нейросети

- Алгоритмы от ИТ-гигантов
- Нейросети и ИИ

Сжатие данных на Linux

TAR.GZ

Использует утилиту tar совместно со сжатием gzip.

- Команда для сжатия папки или файлов: `tar -czvf имя_архива.tar.gz / путь/к/папке_или_файлу`
(Ключи: c — создать архив, z — сжать через gzip, v — показывать процесс, f — записать в файл).
- Команда для распаковки: `tar -xzvf имя_архива.tar.gz`

Сжатие данных на Linux

TAR.XZ

Сжимает файлы сильнее, чем gzip, но требует чуть больше времени и ресурсов процессора.

- Команда для сжатия: `tar -cjvf имя_архива.tar.xz /путь/к/ папке_или_файлу`
- Команда для распаковки: `tar -xjvf имя_архива.tar.xz`

Сжатие данных на Linux

ZIP

Идеально, если архив нужно будет открывать на компьютерах с Windows без установки сторонних программ.

- Команда для сжатия папки со всем содержимым: `zip -r имя_архива.zip /путь/к/папке`
(Ключ `-r` означает «рекурсивно», то есть сжимать вместе со всеми подпапками и файлами внутри).
- Команда для распаковки: `unzip имя_архива.zip`

Сжатие данных на Linux

GUI

В пользовательских дистрибутивах (Ubuntu, Linux Mint, РедОС, Manjaro), интерфейс встроенного проводника позволяет сжимать файлы в пару кликов.

1. Откройте файловый менеджер и выделите нужные файлы или папки.
2. Нажмите по ним правой кнопкой мыши.
3. В контекстном меню выберите пункт «Сжать...»
4. В появившемся окне введите имя архива и выберите желаемый формат из выпадающего списка (.zip, .tar.gz, .7z).
5. Нажмите кнопку «Создать».

Сжатие данных на Windows

GUI

1. Выделите один или несколько файлов/папок, которые нужно сжать.
2. Нажмите по ним правой кнопкой мыши.
3. Вызовите команду сжатия:
 - В Windows 11: В появившемся меню выберите «Сжать в ZIP-файл».
 - В Windows 10 и старых версиях: Выберите пункт «Отправить» $\rightarrow$ «Сжатая ZIP-папка».
4. Рядом появится архив. При желании введите для него новое имя и нажмите Enter.

Для извлечения файлов: Кликните по ZIP-архиву правой кнопкой мыши и выберите «Извлечь все...».



Сжатие данных на Windows

CMD

1. Откройте командную строку
2. Введите команду для создания ZIP-архива: `tar -a -cf имя_архива.zip "путь_к_папке_или_файлу"`
3. (Ключ `-a` автоматически определяет формат сжатия по расширению файла, а `-cf` создает новый архив).

Сжатие через Finder

GUI



Сжатие через Finder

Terminal

1. Перейти с помощью `cd` в папку, в которой лежат ваши файлы
2. Введите команду для создания зашифрованного архива: `zip -er имя_будущего_архива.zip имя_папки_для_сжатия`
3. (Ключ `-e` отвечает за шифрование/пароль, а `-r` — за рекурсивное сжатие всех вложенных файлов).
4. Нажмите Enter. Терминал попросит ввести пароль, а затем подтвердить его

Сравнение

Алгоритм	Эффективность сжатия	Скорость сжатия	Скорость распаковки	Потребление ОЗУ	Главная фишка
DEFLATE	Средняя	Высокая	Очень высокая	Низкое	Максимальная совместимость
LZMA2	Максимальная	Низкая	Высокая	Высокое	Лучший размер архива
Bzip2	Высокая	Низкая	Средняя	Среднее	Эффективен для лог-файлов
Zstd	Высокая	Экстремальная	Экстремальная	Настраиваемое	Идеальный баланс скорости и веса
Brotli	Очень высокая (веб)	Средняя	Очень высокая	Низкое	Заточен под ускорение сайтов